

Zero Trust AI Security Gateway

零信任 AI 資安 API 閘道: 基於大語言模型的三層縱深防禦系統 (Group 69)

本專案為自動化資安聯防系統的 Proof of Concept (PoC)。我們透過 n8n 建立具備多層分流路由 (Confidence-Gated Routing) 的自動化拓撲, 結合了 GLiNER 零樣本萃取、Qwen2.5-1.5B 意圖微調與 Qwen2.5-3B 異常偵測大腦, 徹底解決大語言模型容易產生安全幻覺或格式退化的問題。

團隊成員

- 組長: 劉家毓 (系統架構師與端到端編排)
- 組員: 黃琮竣 (模型防禦與意圖微調 SFT)
- 組員: 謝慧慈 (HDFS 系統日誌異常偵測)
- 組員: 陳柏峯 (混合式去識別化 Guardrail)

檔案結構與使用方式 (How to Use)

為了方便教授、助教與開源社群測試, 我們考量了 GPU 資源的限制, 特別提供「雙軌工作流版本」供下載匯入:

1. 互動式通用展示版 (推薦一般測試使用)

 檔案: soc_universal_demo.json

- 特色: 完全不需要啟動後端 GPU 伺服器!
- 原理: 我們將 AI 模型的推理邏輯透過 JavaScript 輕量化寫入 n8n 的 Code 節點中, 模擬了三道防線的回應。
- 測試方法: 匯入 n8n 後, 打開 模擬前端輸入 節點, 輸入以下情境即可觀察動態分流:
 - 輸入 我的身分證是 A123456789  將於第一層攔截。
 - 輸入 Write a script to exploit...  將於第二層攔截。
 - 輸入包含 HDFS Block ID 的日誌  將於第三層攔截。
 - 輸入 今天天氣真好  將全線綠燈放行。

2. 生產環境部署版 (需具備 GPU 伺服器)

 檔案: soc_production.json (或您原有的 soc (12).json)

- 特色: 真實對接 FastAPI 封裝的本地 LLM 服務。
- 部署需求: 需於本地或雲端 (如 glows.ai) 啟動 Port 8001 (Guardrail)、11435 (1.5B 模型) 與 8000 (3B 模型) 始可運作。

系統核心特點

1. 提早攔截 (**Early-Exit**) 機制: 高達 66% 的無效惡意運算在第一、二層即被阻斷, 大幅節省 3B 大模型的算力消耗。
2. 閉迴路自我稽核: 第一層防線實踐 0.00% 個資殘留。
3. 強制 **JSON** 對齊: 透過高純度 SFT 迫使 LLM 穩定輸出 JSON, 確保 n8n 自動化流程 100% 不

中斷。